

Predicción de Mortalidad por Fallo Cardíaco Mediante Técnicas de Machine Learning

Reporte Técnico – Ejecutivo

Lucas Cordero Lesly Monserrat
Martínez León José Emilio
Rodríguez Rodríguez Ian Alam
Rojas Lagunas Kevin Antonio
Silva Pérez Liliana

*Diplomado: Introducción Analítica a la Ciencia de Datos
2026*

1. Marco Contextual y Objetivo.

El fallo cardíaco constituye una de las patologías más críticas en la medicina contemporánea, caracterizada por una elevada morbilidad que demanda estrategias de intervención temprana y precisa. La integración de la analítica avanzada en registros médicos electrónicos no es simplemente un ejercicio técnico, sino un imperativo estratégico para mejorar la supervivencia del paciente y la eficiencia operativa hospitalaria. Este informe detalla el análisis y modelado de datos procedentes del Instituto de Cardiología de Faisalabad y el Hospital Aliado de Faisalabad (Pakistán), basados en el estudio de Ahmad et al. (2017) y disponibles en Kaggle.

La meta técnica central es identificar la arquitectura de Machine Learning con mayor capacidad para predecir el evento de mortalidad (**DEATH_EVENT**), garantizando que la selección del modelo priorice la seguridad clínica por encima de la complejidad algorítmica.

2. Resumen Ejecutivo

El presente análisis abordó la predicción de mortalidad de pacientes mediante técnicas de ciencia de datos. Debido a la naturaleza médica del problema, se determinó que **el costo de un Falso Negativo (predecir que un paciente no fallecerá, negándole cuidados intensivos) es clínicamente inaceptable**. Por lo tanto, el proyecto prioriza maximizar la métrica de **Recall** (Sensibilidad).

Tras evaluar múltiples modelos (Regresión Logística, Random Forest, AdaBoost, XGBoost y MLP), se concluyó que los modelos lineales (específicamente la Regresión Logística con optimización de hiperparámetros) ofrecieron la mejor capacidad de generalización y el Recall más alto para la clase minoritaria (fallecimientos). Las variables clínicas más determinantes para predecir el riesgo fueron los niveles de creatinina sérica, la fracción de eyección y la edad del paciente.


3. Análisis Exploratorio de Datos (EDA) y Preprocesamiento

Se analizó un dataset de 299 pacientes descrita por 13 características (numéricas y categóricas). Durante la revisión de calidad no se identificaron valores nulos ni inconsistencias relevantes. Asimismo, la variable 'time' fue excluida del proceso de entrenamiento debido a que contiene información posterior al evento clínico, lo que produciría *data leakage* y generaría una sobreestimación artificial del desempeño del modelo.

El análisis exploratorio permitió comprender la distribución de las variables y detectar características que influyen directamente en el modelado predictivo.


Las observaciones clave durante esta fase fueron:

- **Variables Críticas:** Se analizaron factores como la edad (age) y la fracción de eyección (ejection_fraction). Y detectamos que es de especial relevancia la creatinina sérica (serum_creatinine), definida textualmente en la fuente como un "factor determinante conocido de fallos cardíacos", lo que valida su inclusión como predictor de alto impacto.
- **Manejo del Desbalance de Clases:** En primer lugar, la distribución de clases mostró un desbalance moderado: aproximadamente el 67.9% de los pacientes sobrevivieron, mientras que el 32.1% fallecieron. Aunque este desbalance no es extremo, puede inducir a los modelos a favorecer la clase mayoritaria, por lo que posteriormente se implementaron estrategias de estratificación y ponderación mediante `class_weight='balanced'`.




- **Escalamiento y Distribución de Variables:** Las variables numéricas, en especial **creatinine_phosphokinase** (CPK) y **platelets** (plaquetas), mostraron escalas extremadamente dispares (~1K y ~100K) en comparación con el resto, además los box-plots evidencian la presencia significativa de valores atípicos (outliers).

Análisis Comparativo de Variables Numéricas




- Por ello, se justificó el uso de **RobustScaler** previo al entrenamiento. En cuanto a las variables categóricas, el análisis visual demostró que características como el sexo o la diabetes no presentaban una diferencia tan marcada en la tasa de mortalidad.

Tasa de Fallecimientos por Variables Categóricas



- Análisis de Correlación:** La matriz de correlación mostró que `serum_creatinine` mantiene la asociación positiva más alta con el evento de mortalidad, mientras que `ejection_fraction` presenta una correlación negativa, indicando que una menor capacidad de bombeo incrementa el riesgo clínico. La edad también mostró una asociación positiva con la mortalidad, consistente con la evidencia médica. Los resultados del EDA permitieron definir una estrategia de preprocesamiento robusta y orientada a preservar la capacidad predictiva de los modelos, minimizando sesgos derivados de la distribución de los datos.



4. Metodología y Comparación de Modelos.

Metodología.

Una vez concluido el análisis exploratorio se diseñó un flujo de trabajo orientado a maximizar la capacidad de generalización del modelo y reducir el riesgo de sobreajuste. El pipeline incluyó limpieza de datos, separación de variables predictoras y objetivo, escalamiento, entrenamiento, validación y evaluación.

Para preservar la proporción de pacientes fallecidos y sobrevivientes se realizó una partición estratificada de 80 % para entrenamiento y 20 % para prueba.

Las variables numéricas fueron transformadas mediante RobustScaler debido a la presencia de valores atípicos. Este método utiliza la mediana y el rango intercuartílico, disminuyendo la influencia de observaciones extremas.


El desempeño se evaluó mediante validación cruzada estratificada utilizando Recall, F1-Score y ROC-AUC como métricas principales.

Resultados Generales y Comparación.


Se compararon diferentes algoritmos de clasificación supervisada con el objetivo de seleccionar el modelo que ofreciera el mejor equilibrio entre sensibilidad, capacidad discriminatoria e interpretabilidad.

Modelo	Precision Promedio	σ Precision	Recall Promedio	σ Recall	F1 Promedio	σ F1	ROC AUC Promedio	σ ROC AUC
Regresión Logística	5.800	706	7.092	1.105	6.321	625	7.767	663
Regresión Logística L1	5.749	673	6.989	1.137	6.242	607	7.734	676
Regresión Logística L2	5.800	706	7.092	1.105	6.321	625	7.767	663
R.L. GridSearch	4.569	582	8.058	974	5.808	630	7.586	766
R.L. RandomSearch	4.600	580	8.020	975	5.824	635	7.589	772
Random Forest	6.298	782	6.292	1.308	6.244	936	7.834	711
AdaBoost GridSearchCV	6.338	1.005	6.562	1.354	6.351	895	7.785	689

Comparación de Rendimiento entre Modelos





1. **Regresión Logística (GLM):** Utilizado como modelo base (*baseline*). Mostró una notable robustez frente al conjunto de datos, logrando un Recall promedio altamente competitivo. Las regularizaciones L1 y L2 no mostraron mejoras drásticas, indicando que el modelo lineal estándar maneja bien este volumen de datos.





2. **Modelos de Ensamblaje (Random Forest, AdaBoost, XGBoost):** Aunque potentes, mostraron un desempeño inferior en la métrica de interés (Recall) durante la validación cruzada en comparación con los modelos lineales.
3. **Redes Neuronales (MLP):** Presentó el peor desempeño clínico. Esto se justifica técnicamente por la escasez de datos, ya que los Perceptrones Multicapa requieren volúmenes masivos de datos para ajustar sus pesos.

Optimización del Mejor Modelo



Para mejorar la tasa de detección y reducir al mínimo los Falsos Negativos, se aplicó una búsqueda exhaustiva de hiperparámetros (**GridSearchCV**). La **Regresión Logística con GridSearchCV** logró el mejor equilibrio y una excelente capacidad de capturar verdaderos positivos.





5. Interpretación Médica y Técnica del Modelo (Análisis SHAP)

Para garantizar que los modelos no operan como "cajas negras" y tengan sentido clínico, se utilizó la interpretabilidad de **SHAP**.



Las gráficas arrojaron un consenso claro:

1. **serum_creatinine (Creatinina Sérica):** Es la variable más predictiva. El gráfico SHAP demuestra que valores altos (puntos a la derecha del eje de impacto) incrementan drásticamente la probabilidad de fallecimiento, alineándose con el conocimiento de que es un indicador de falla renal aguda.
2. **ejection_fraction (Fracción de Eyección):** Valores bajos impulsan la predicción de muerte. Clínicamente, indica que el corazón bombea sangre de manera ineficiente.
3. **age (Edad):** A mayor edad, se observa un impacto positivo en la predicción de mortalidad, lo cual es coherente con el riesgo natural asociado a pacientes mayores.

6. Conclusiones

1. **Simplicidad vs. Complejidad:** Para este conjunto de datos clínico específico (pequeño y con ruido), un modelo lineal simple y bien regularizado (Regresión Logística) superó a algoritmos altamente complejos computacionalmente.
2. **Prioridad de Métricas:** La decisión de priorizar el **Recall** guió exitosamente el desarrollo. Un modelo con un *Accuracy* alto pero bajo *Recall* habría sido engañoso e inútil en un entorno hospitalario.
3. **Confiabilidad y Transparencia:** Gracias a la interpretabilidad visual (SHAP y EDA), se comprobó que el modelo aprende de las variables correctas (función de bombeo y toxicidad sanguínea), logrando un producto técnico que los médicos pueden entender y en el cual pueden confiar.